Análise Estatística de Fatores de Risco para Doença Coronária

AUTHOR
Wenderson Santos

Introdução

O dataset provém de um estudo que analisou 297 pacientes na Cleveland Clinic para avaliação da Doença Coronária;

O experimento envolveu 3 estágios:

- Teste de esforço (protocolo de Bruce)
- Cinefluoroscopia
- Angiografia coronária
- Cintilografia com Tálio-201

Variáveis analisadas

- age
- sex
- cp : tipo de dor no peito
    - Angina Típica: Atende a três critérios (localização atrás do osso do peito, provocada por esforço/estresse e aliviada por repouso).
    - Angina Atípica: Atende a apenas dois desses critérios.
    - Dor Não Anginosa: Atende a apenas um ou nenhum dos critérios, sugerindo que a causa pode ser muscular ou gástrica (não cardíaca).
    - Assintomático: O paciente não sente dor, mas o médico ainda assim solicitou os exames devido a outros fatores de risco (como idade ou histórico familiar).
- thalach : Frequência cardíaca máxima atingida antes da exaustão ou sintomas (no teste de esforço).
- exang : Indica se o paciente sentiu angina (dor) durante o exercício.
- oldpeak : diferença entre a posição do segmento ST (ECG) no repouso e no pico do esforço (thalac) (quanto maior essa diferença, maior é a área do coração que sofre por falta de sangue)
- slope : Enquanto o oldpeak diz o quanto a linha afundou, o slope diz como ela se comporta logo após o afundamento. Existem três tipos principais de inclinação:
    - Value 0: Upsloping (Ascendente): A linha afunda, mas sobe rápido. É comum em exercícios intensos e nem sempre indica doença grave.

- Value 1: Flat (Plano): A linha afunda e fica “reta”. É um sinal clássico e preocupante de isquemia.
- Value 2: Downsloping (Descendente): A linha afunda e continua descendo. É o sinal mais grave de todos, indicando que o coração está em alto sofrimento isquêmico. (mesmo após a interrupção do esforço)

- ca : Número de vasos principais com depósitos de cálcio ou interrupções no fluxo.
  - 0: Nenhuma calcificação significativa (indício de artérias limpas)
  - 1, 2 o u 3: Indica que a doença está presente em um, dois ou três vasos principais.
- thal : Avalia se o sangue está chegando a todas as partes do coração durante o repouso e após o esforço.
  - 0 = Normal: O contraste se distribui uniformemente por todo o coração.
  - 1 = Fixed Defect (Defeito Fixo): Uma parte do coração não recebe o contraste nem no esforço, nem no repouso. Isso geralmente indica tecido morto (cicatriz de um infarto antigo).
  - 2 = Reversable Defect (Defeito Reversível): O coração parece normal em repouso, mas “falta sangue” em alguma região durante o esforço. Isso é o sinal clássico de isquemia ativa: a artéria está entupida, mas o tecido ainda está vivo e sofrendo.
- condition (target)
- trestbps : É a pressão arterial medida no momento da internação.
- fbs : Glicemia de Jejum é maior ou menor que 120mg/dl (binário)
- chol : nível total de colesterol no sangue.
- restecg :
  - Value 0 (Normal): O coração em repouso não apresenta irregularidades elétricas.
  - Value 1 (Anormalidade de Onda ST-T): O coração já mostra sinais de sofrimento mesmo sem fazer esforço. É um sinal de alerta precoce.
  - Value 2 (Hipertrofia Ventricular Esquerda): Indica que o músculo do coração está “inchado” (grosso), geralmente por ter que fazer muita força para bombear o sangue contra uma pressão alta crônica.

Modelagem com Regressão Logística

```
source(here::here("R", "modelPrep.R"))
```

Modelo com todas as variáveis

```r
modelo_completo <- glm(condition~ ., data = treino, family = "binomial")
```

```r
summary(modelo_completo)
```

```
Call:
glm(formula = condition ~ ., family = "binomial", data = treino)

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept) -6.194972   3.665480  -1.690 0.091012 .
age         -0.026817   0.029325  -0.914 0.360473
sex1         1.751307   0.623152   2.810 0.004948 **
cp1          1.905287   0.923121   2.064 0.039021 *
cp2          0.321896   0.847290   0.380 0.704011
cp3          2.768984   0.864891   3.202 0.001367 **
trestbps     0.014047   0.014133   0.994 0.320261
chol         0.005760   0.005651   1.019 0.308039
fbs1        -0.407723   0.701053  -0.582 0.560845
restecg1     1.120803   3.359086   0.334 0.738634
restecg2     0.261999   0.460966   0.568 0.569784
thalach     -0.011517   0.012639  -0.911 0.362196
exang1       0.337282   0.550815   0.612 0.540317
oldpeak      0.649698   0.283217   2.294 0.021791 *
slope1       1.341601   0.600799   2.233 0.025547 *
slope2       0.402313   1.023407   0.393 0.694237
ca1          2.575920   0.637209   4.043 5.29e-05 ***
ca2          3.119482   0.851992   3.661 0.000251 ***
ca3          2.982628   1.206518   2.472 0.013432 *
thal1       -0.336710   0.979476  -0.344 0.731023
thal2        1.486334   0.518928   2.864 0.004180 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 328.58  on 237  degrees of freedom
Residual deviance: 141.26  on 217  degrees of freedom
AIC: 183.26

Number of Fisher Scoring iterations: 6
```

O AIC foi de 183.26.

Embora o modelo explique bem a variável alvo, é possível observar que a maioria das covariáveis não é estatísticamente significativa, segundo o teste de Wald.

Para verificar isso, faremos um **Teste de Razão de Verossimilhanças**, verificando o impacto da retirada de cada variável.

```r
pander::pander(  car::Anova(modelo_completo, type = "III", test = "LR")  )
```

Analysis of Deviance Table (Type III tests)

	LR Chisq	Df	Pr(>Chisq)
age	0.8384	1	0.3599
sex	8.776	1	0.003053
cp	20.58	3	0.0001287
trestbps	0.9972	1	0.318
chol	1.046	1	0.3065
fbs	0.3411	1	0.5592
restecg	0.4147	2	0.8127
thalach	0.8493	1	0.3568
exang	0.3705	1	0.5427
oldpeak	5.789	1	0.01612
slope	5.689	2	0.05818
ca	30.8	3	9.375e-07
thal	10.29	2	0.005832

Aqui é possível obervar que as variáveis que contribuem significativamente (ao nível de 5%) para o modelo são: **sex, cp, oldpeak, slope, ca e thal**.

Para verificar o impacto no modelo ao retirar essas variáveis, faremos o **Teste de Razão de Verossimilhanças** entre o modelo completo e o modelo reduzido.

```
modelo_reduzido <- glm( condition ~  sex + cp +
                        oldpeak + slope + ca + thal,
                        data = treino,
                        family = "binomial"
                      )
```

```
pander::pander(  anova(modelo_completo, modelo_reduzido, test = "Chisq")  )
```

Analysis of Deviance Table

Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
217	141.3	NA	NA	NA
225	146	-8	-4.728	0.7863

O p-valor foi de 0.7863, ou seja, não há evidências significativas de que o modelo completo seja melhor que o modelo reduzido. Então prosseguiremos a análise usando o modelo reduzido.

Modelo reduzido

```
pander::pander(  car::Anova(modelo_reduzido, type = "III", test = "LR")  )
```

Analysis of Deviance Table (Type III tests)

	LR Chisq	Df	Pr(>Chisq)
sex	7.552	1	0.005995
cp	33.87	3	2.114e-07
oldpeak	8.84	1	0.002947
slope	7.529	2	0.02318
ca	36.4	3	6.159e-08
thal	13.53	2	0.001152

Todas variáveis contribuem significativamente para o modelo.

Analisando os coeficientes

```r
summary(modelo_reduzido)
```

```
Call:
glm(formula = condition ~ sex + cp + oldpeak + slope + ca + thal,
    family = "binomial", data = treino)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -5.9413     1.0866  -5.468 4.55e-08 ***
sex1          1.5013     0.5701   2.633 0.008457 **
cp1           1.9084     0.8790   2.171 0.029920 *
cp2           0.1321     0.8094   0.163 0.870380
cp3           2.8874     0.7625   3.787 0.000153 ***
oldpeak       0.7464     0.2675   2.790 0.005265 **
slope1        1.4200     0.5586   2.542 0.011027 *
slope2        0.3778     0.9772   0.387 0.699022
ca1           2.4781     0.5834   4.248 2.16e-05 ***
ca2           2.7872     0.7884   3.535 0.000407 ***
ca3           3.0723     1.1399   2.695 0.007031 **
thal1        -0.4301     0.9152  -0.470 0.638360
thal2         1.6062     0.4905   3.275 0.001058 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 328.58  on 237  degrees of freedom
Residual deviance: 145.99  on 225  degrees of freedom
AIC: 171.99

Number of Fisher Scoring iterations: 6
```

O AIC do modelo reduzido (171.99) foi menor que o do modelo completo, e a Deviance Residual foi aproximadamente igual. Ou seja, o modelo reduzido conseguiu explicar tão bem os dados quanto o

aproximadamente igual. Ou seja, o modelo reduzido consegue explicar tão bem os dados quanto o completo.

```
pander::pander(  gerar_tabela_or(modelo_reduzido)  )
```

	OR	IC_2.5	IC_97.5	amplitude	p_valor
(Intercept)	0.0026	3e-04	0.0187	0.0184	0
sex1	4.487	1.524	14.54	13.02	0.0085
cp1	6.742	1.257	40.86	39.6	0.0299
cp2	1.141	0.2326	5.755	5.522	0.8704
cp3	17.95	4.359	89.08	84.72	2e-04
oldpeak	2.109	1.278	3.68	2.401	0.0053
slope1	4.137	1.427	12.99	11.56	0.011
slope2	1.459	0.2034	9.701	9.497	0.699
ca1	11.92	3.986	39.93	35.94	0
ca2	16.24	3.77	83.96	80.19	4e-04
ca3	21.59	2.873	261.3	258.5	0.007
thal1	0.6504	0.1084	4.116	4.008	0.6384
thal2	4.984	1.94	13.45	11.51	0.0011

É possível observar que alguns coeficientes estimados são muito incertos (o modelo não conseguiu definir se a associação entre a respectiva variável e o target era positiva ou negativa) (o 1 está contido no IC de 95%);

Essas variáveis foram : cp2, slope2 e thal1

Segundo o teste de wald, essas variáveis não são significativas para o modelo.

Outros coeficientes tinham IC com amplitude grande demais, como foi o caso de cp1, cp3, ca2, ca3,

Ou seja, o modelo não conseguiu estimar precisamente esses coeficientes

Uma possível motivação para isso é que essas variáveis categóricas possuem algumas classes subrepresentadas no dataset, dificultando a estimação dos parâmetros.

Treinando modelo com agrupamento de classes subrepresentadas

- cp :
  - com_dor : {0, 1, 2}
  - sem_dor : {3}
- slope :
  - asc : {0}
  - not_asc : {1, 2}
- ca :

    - zero : {0}
    - not_zero : {1, 2, 3}
- thal :
    - normal : {0}
    - not_normal : {1, 2}

```
modelo_agrupado <- glm(condition ~ sex+ cp +
                   oldpeak + slope + ca + thal,
                 data = treino_agrupado,
                 family = "binomial")
```

```
summary(modelo_agrupado)
```

```
Call:
glm(formula = condition ~ sex + cp + oldpeak + slope + ca + thal,
    family = "binomial", data = treino_agrupado)

Coefficients:
                Estimate Std. Error z value Pr(>|z|)
(Intercept)      -2.1741     0.5627  -3.864 0.000112 ***
sex1              1.1387     0.4984   2.285 0.022342 *
cp_sem dor        2.1247     0.4299   4.943 7.70e-07 ***
oldpeak           0.5708     0.2290   2.493 0.012669 *
slope_not_asc     0.9416     0.4819   1.954 0.050691 .
ca_zero          -2.3326     0.4465  -5.224 1.75e-07 ***
thal_not_normal   1.2461     0.4543   2.743 0.006092 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 328.58  on 237  degrees of freedom
Residual deviance: 157.70  on 231  degrees of freedom
AIC: 171.7

Number of Fisher Scoring iterations: 6
```

```
pander::pander(  gerar_tabela_or(modelo_agrupado)  )
```

	OR	IC_2.5	IC_97.5	amplitude	p_valor
(Intercept)	0.1137	0.0346	0.3199	0.2853	1e-04
sex1	3.123	1.196	8.564	7.368	0.0223
cp_sem dor	8.37	3.71	20.25	16.54	0
oldpeak	1.77	1.15	2.836	1.686	0.0127
slope_not_asc	2.564	1.004	6.721	5.717	0.0507
ca_zero	0.097	0.0385	0.2243	0.1859	0
thal_not_normal	3.477	1.439	8.636	7.198	0.0061

Aqui, é possível observar que os parâmetros estão mais estáveis e os odds ratios estão mais de acordo com os insights obtidos na EDA;

Teste razão de verossimilhanças

```
pander::pander(  anova(modelo_reduzido, modelo_agrupado, test = "Chisq"),
                 caption= "Teste de Razão de Verossimilhanças entre o modelo reduzido e o ag
```

Teste de Razão de Verossimilhanças entre o modelo reduzido e o agrupado

Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
225	146	NA	NA	NA
231	157.7	-6	-11.71	0.06867

Ao nível de 5%, a diferença entre os dois modelos não é significativa. De acordo com o princípio da parcimônia e estabilidade dos parâmetros, prosseguiremos com a análise usando o modelo_agrupado.

Interpretação dos coeficientes do modelo

- Ser homem aumenta a chance de ter a doença em 3 vezes;
- Ser assintomático aumenta a chance de ter a doença em 8 vezes;
- Para cada unidade de oldpeak, a chance de ter a doença aumenta em 77%;
- Pacientes com inclinação não ascendente do segmento ST apresentam uma chance 2.5 vezes maior de ter a doença;
- Não ter vasos coloridos na fluoroscopia diminui a chance de ter a doença em 90%;
- Pacientes com resultados de talassemia (thal) considerados não normais possuem 3.5 vezes mais chance de possuirem a doença;

Qualidade do ajuste do modelo

```
performance::performance_hosmer(modelo_agrupado)
```

```
# Hosmer-Lemeshow Goodness-of-Fit Test

  Chi-squared: 4.467
           df: 8
      p-value: 0.813

Summary: model seems to fit well.
```

Ao nível de significância de 5%, não foi possível rejeitar H_0, portanto não há evidências contra um mal ajuste do modelo.

Diagnóstico do modelo

```
par(mfrow = c(2, 2)) # Divide a tela em 2x2
plot(modelo_agrupado)
```

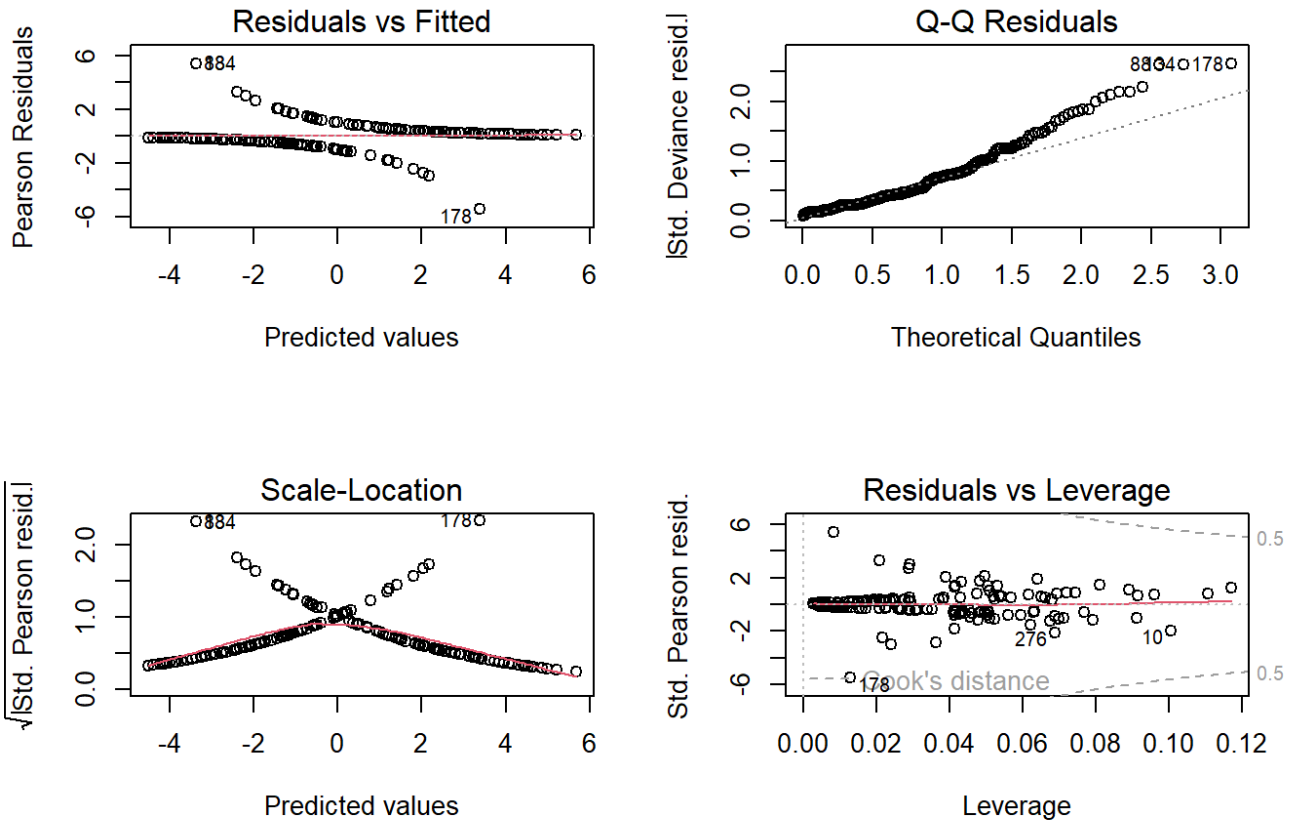


```
par(mfrow = c(1, 1)) # Volta ao normal depois
```

```
leverage <- hatvalues(modelo_agrupado)
preditos <- predict(modelo_agrupado, type = "response")

# Gerando o gráfico
plot(preditos, leverage,
     main = "Leverage vs Predicted Values",
     xlab = "Probabilidade Predita",
     ylab = "Alavancagem (Leverage)",
    )

# linha de corte (2p/n)
p <- length(coef(modelo_agrupado))
n <- nrow(model.frame(modelo_agrupado))
abline(h = 2 * p / n, col = "red", lty = 2)
```

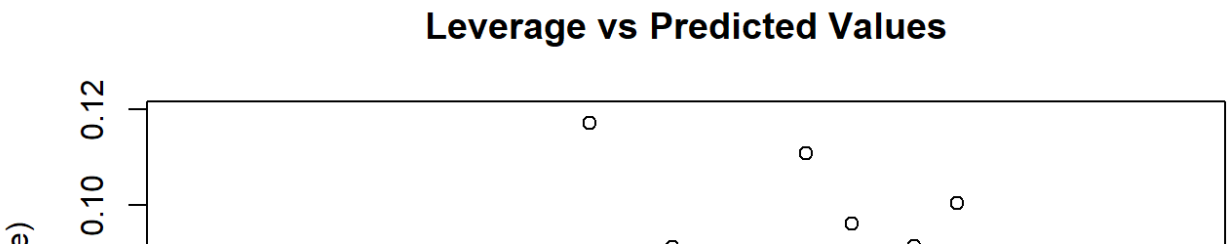

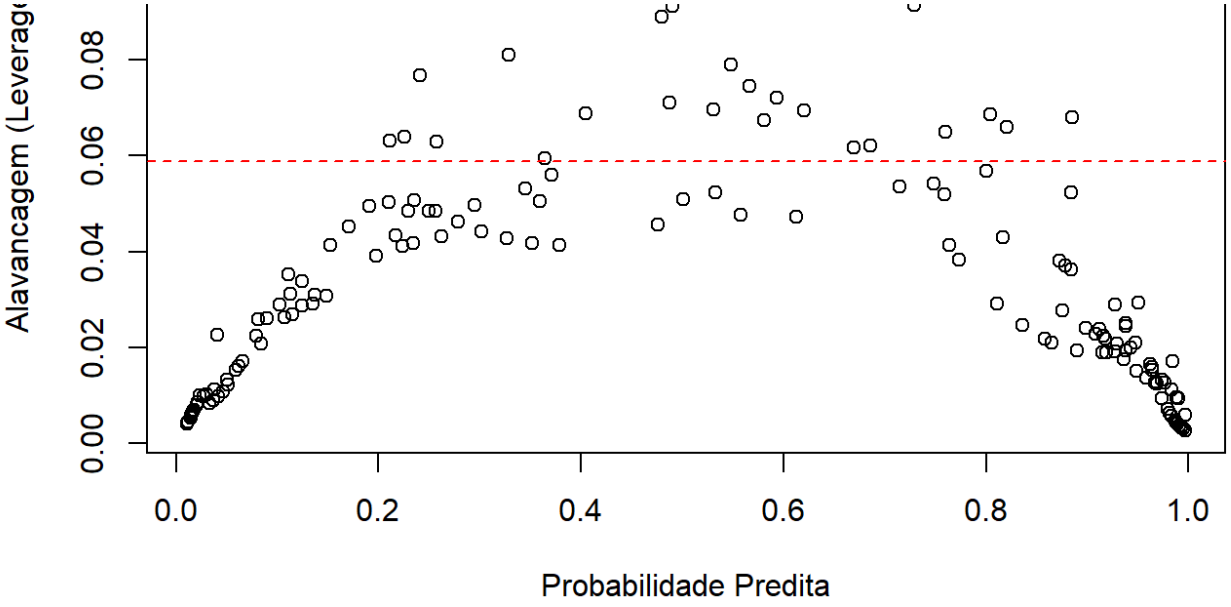


```r
# 1. Extrai o componente da deviance ao quadrado para cada observação
d_quadrado <- residuals(modelo_agrupado, type = "deviance")^2
preditos <- predict(modelo_agrupado, type = "response")

# 2. Gera o gráfico
plot(preditos, d_quadrado,
     xlab = "Valores preditos",
     ylab = "d²",
     main = "Componente da Deviance² vs Valores Preditos",
     pch = 1, col = "black")

# 3. Adiciona a linha de corte sugerida (Chi-quadrado com 1 gl e 95% de confiança)
abline(h = 3.84, linetype = "dashed", col = "red") # 3.84 é o valor exato para p < 0.05
```

```
Warning in int_abline(a = a, b = b, h = h, v = v, untf = untf, ...): "linetype"
is not a graphical parameter
```

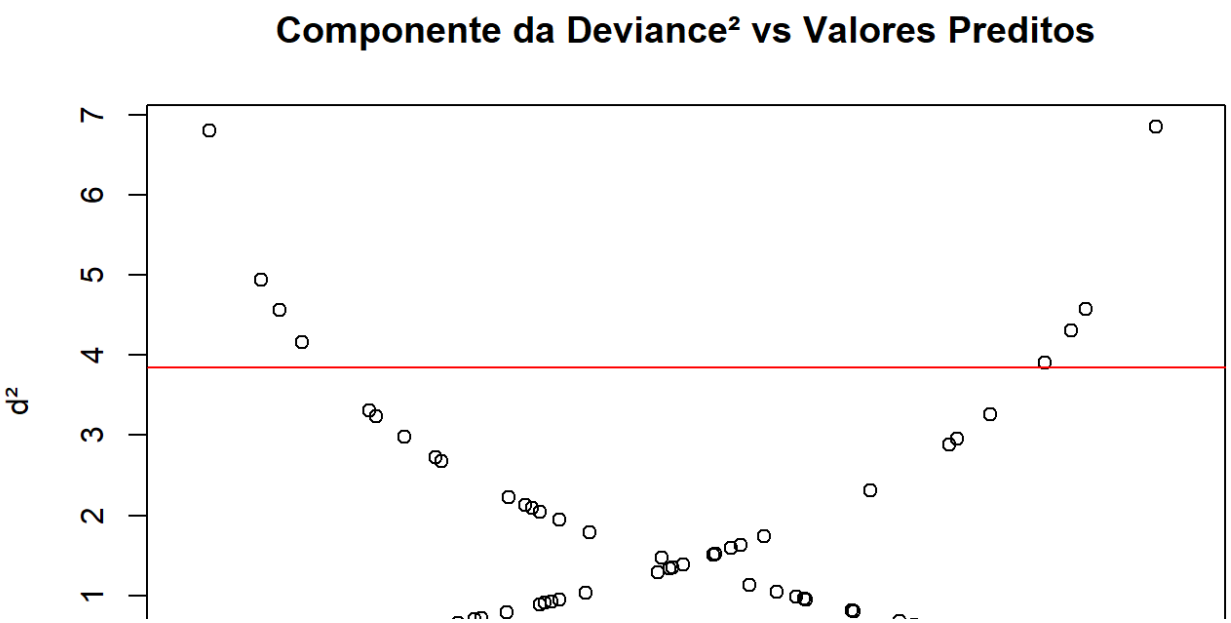

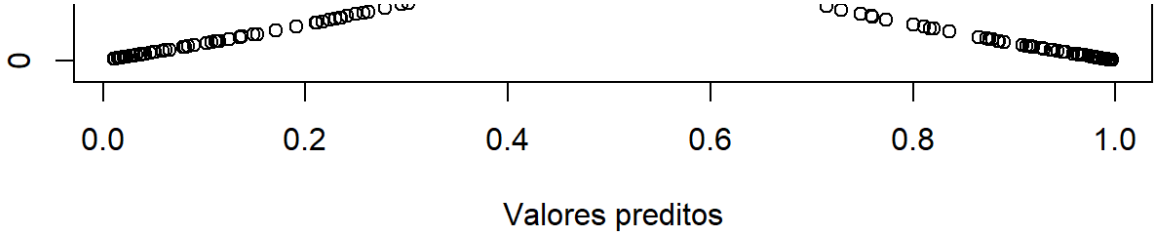

É possível observar a presença de algums valores anômalos;

```
# dataframe com os dados originais + o d2 e o valor predito
dados_diagnostico <- data.frame(
  d2 = d_quadrado,
  probabilidade = predict(modelo_agrupado, type = "response"),
  model.frame(modelo_agrupado)
)

# Filtramos apenas os pontos acima da linha vermelha (3.84)
outliers_deviance <- dados_diagnostico[dados_diagnostico$d2 > 3.84, ]

# Ordenamos do maior erro para o menor
outliers_deviance <- outliers_deviance[order(-outliers_deviance$d2), ]

# Visualizar
pander::pander(outliers_deviance)
```

Table continues below

	d2	probabilidade	condition	sex	cp	oldpeak
178	6.848	0.9674	Saudavel	1	_sem dor	0.2
88	6.804	0.03331	Doente	1	_com dor	0
134	6.804	0.03331	Doente	1	_com dor	0
206	4.941	0.08455	Doente	0	_sem dor	0
91	4.574	0.8984	Saudavel	1	_com dor	1.8
33	4.564	0.1021	Doente	0	_com dor	0
177	4.313	0.8843	Saudavel	0	_sem dor	2
35	4.167	0.1245	Doente	1	_com dor	0.3
228	3.907	0.8582	Saudavel	1	_sem dor	1.5

	slope	ca	thal
178	_not_asc	_not_zero	_not_normal
88	_asc	_zero	_normal
134	_asc	_zero	_normal
206	_asc	_zero	_normal
91	_not_asc	_not_zero	_not_normal
33	_asc	_not_zero	_normal

177	_not_asc	_not_zero	_normal
35	_asc	_zero	_not_normal
228	_not_asc	_zero	_not_normal

É possível observar casos em que os indivíduos carregam características de pessoas saudáveis, mas na verdade são doentes e vice versa; Entretanto essas observações são válidas, então não removeremos essas observações;